



5G KONUMLANDIRMA YARIŞMASI

ÖN TASARIM RAPORU

Takım Adı: High5
Takım ID: 737864
Başvuru ID: 3616454

İÇİNDEKİLER

1.	PROJE ÖZETİ (10 PUAN).....	3
2.	TAKIM ŞEMASI.....	3
3.	SİSTEM ÖN TASARIMI (65 PUAN)	3
3.1.	Proje Mevcut Durum Değerlendirmesi (15 Puan).....	3
3.2.	Algoritma Tasarımı (50 Puan).....	4
3.2.1	Veri Setleri (5 Puan)	4
3.2.2	Konumlandırma Algoritması (20 Puan).....	4
3.2.3	Doğruluk ve Hassasiyet Analizi (20 Puan).....	5
3.2.4	Akış Şeması (5 Puan).....	5
4.	ÖZGÜNLÜK (20 PUAN)	5
5.	KAYNAKÇA (5 PUAN).....	6

1. PROJE ÖZETİ (10 PUAN)

Bu çalışmada, İTÜ Ayazağa Kampüsü'nde toplanan 5G saha verileri işlenerek cihaz konumlarının makine öğrenimi ile tahmini amaçlanmıştır. Veriler birleştirilip eksikler giderilmiş, yapılandırma ve harita bilgileri entegre edilerek öznitelik mühendisliği uygulanmıştır.

XGBoost ile temel modelleme gerçekleştirilmiş; zaman bağımlılığı dikkate alınmadığı için veri sızıntısı ve aşırı öğrenme riski gözlemlenmiştir. Konfigürasyon verilerinde yer almayan PCI'lara ait teknik bilgilerin, ölçüm ve coğrafi verilerle tahmini hedeflenmektedir.

Zaman serisi (ARIMAX, SARIMAX, LSTM, STL+ML) ve DBSCAN tabanlı yaklaşımlar test edilerek farklı veri yapılarında model performansı karşılaştırılacaktır. DBSCAN ile yeni öznitelikler veya veri çerçeveleri türetilerek hibrit modeller denenebilecektir.

Doğruluk analizinde Euclidean Distance temelli MAE ve RMSE metrikleri kullanılacak, kampüs ölçeğine uygun alternatif mesafe ölçütleriyle karşılaştırmalar yapılacaktır.

2. TAKIM ŞEMASI

SAYI	TAKIMDAKİ GÖREVİ	EĞİTİM SEVİYESİ	SINIF	ÜYE ROLÜ
1	Tarık Tuna Taşaltı	Yüksek Lisans	2	Kaptan
2	Abdulkadir Temizoğlu	Lisans	3	Üye
3	Elif Öznur Yeşil	Lisans	1	Üye
4	Kutay Doğan	Yüksek Lisans	B. Hazırlık	Üye
5	Osman Tekdamar	Lisans	4	Üye

3. SİSTEM ÖN TASARIMI (65 PUAN)


3.1. Proje Mevcut Durum Değerlendirmesi (15 Puan)

Saha verileri birleştirilmiş, eksik değerler (forward fill, ortalama, mod, interpolasyon) yöntemleriyle tamamlanmıştır.



İlk model XGBoost ile kurulmuş, zaman bağımlılığı dikkate alınmadığı için data leakage ve overfitting riski gözlemlenmiştir. İlk görselde, modelin tahmin doğruluğu renk skalasıyla ifade edilmiştir: mavi tonlar düşük hataları, kırmızı tonlar yüksek sapmaları göstermektedir.

İTÜ Ayazağa Kampüsü Ölçüm Güzergahı ve Baz İstasyonu Sektör Kapsamları (Zamana Bağlı Takip)



Görselde, mevcut PCI'lara ait istasyon yönleri ve kapsama alanları ile ölçüm sürecindeki zaman bilgisi skalasındaki renklere göre gösterilmiştir. Verinin ardışık ve zaman serisi niteliği fark edilmiş, kapsama sınırları konfigürasyon ve saha verilerine dayanarak çevresel etkenler olmaksızın çizilmiştir.

3.2. Algoritma Tasarımı (50 Puan)

3.2.1 Veri Setleri (5 Puan)

Modellemede, tahmin edilmesi hedeflenen cihaz konum bilgileri (latitude ve longitude) için downlink, uplink ve scanner verilerinden oluşan üç saha ölçüm seti ile hücre teknik bilgilerini içeren bir konfigürasyon veri seti kullanılmıştır. Saha ölçümleri hücre bilgileriyle birleştirilmiş, kampüs harita verileri ise bu aşamada yalnızca görselleştirme amacıyla değerlendirilmiştir. Veri setleri, sinyal davranışını hem şebeke yapısı hem de çevresel faktörlerle birlikte bütüncül şekilde modelleyebilmek amacıyla seçilmiştir.

3.2.2 Konumlandırma Algoritması (20 Puan)

Saha ölçüm verileri birleştirilmiş, eksikler giderilmiş ve konfigürasyon bilgileri veri setine eklenmiştir. Veri yapısının zaman bağımlılığı içermesi nedeniyle geleneksel modellemede doğruluk sınırlı kalmış, bu nedenle daha uygun yöntemler geliştirilmesi hedeflenmiştir. Ayrıca, konfigürasyon verisinde eksik olan bazı PCI'lara ait koordinat ve yönelim gibi teknik bilgiler, kampüs verileri ve ölçümlerden faydalanılarak tahmin edilecek ve modelin istasyon bazlı bilgileri daha doğru öğrenmesi sağlanacaktır.

Zaman serisi yaklaşımı, ölçümlerin ardışık ve tek cihazdan geldiği yapıya uygun olarak seçilmiştir. ARIMAX, SARIMAX, LSTM ve STL + makine öğrenimi modelleriyle hem ham veri hem de PCI bazlı alt kümelerde modelleme yapılacak, walk-forward validation yöntemiyle değerlendirme gerçekleştirilecektir.


Alternatif olarak, DBSCAN ile saha verileri üzerinden yoğunluk temelli kümeler oluşturulacak, hedef değişkenler sürece dahil edilmeden yeni öznitelikler veya alt veri setleri üretilecektir. Bu sayede, veri sızıntısı önlenecek, konumsal örüntülerden faydalanılarak model başarımı artırılacaktır. Sonuçlar zaman serisi modelleri ile karşılaştırılacak, gerektiğinde hibrit yaklaşımlar değerlendirilecektir.

3.2.3 Doğruluk ve Hassasiyet Analizi (20 Puan)

Konum tahminlerinin başarısı, tahmin edilen ve gerçek koordinatlar arasındaki fark üzerinden Euclidean Distance ile ölçülecek ve bu metrik doğrudan loss function olarak kullanılacaktır. Euclidean Distance, iki nokta arasındaki düzlemsel mesafeyi ölçmek için yaygın olarak kullanılan bir metriktir[1]. Performans değerlendirmesi için MAE ve RMSE gibi hata ölçütleri kullanılacaktır.

Kampüs ölçeğinde çalışıldığı için düzlemsel mesafeler yeterli görülmüş; bu nedenle Minkowski ve Chebyshev gibi alternatifler değerlendirilecektir. Minkowski Distance, farklı p değerleriyle özelleştirilebilen bir mesafe ölçüsüdür[2]. Chebyshev Distance ise, iki nokta arasındaki en büyük koordinat farkını baz alır ve özellikle ızgara tabanlı uygulamalarda kullanılır[3]. Manhattan Distance, çapraz yayılımı dışladığı için uygun bulunmamıştır.

3.2.4 Akış Şeması (5 Puan)



4. ÖZGÜNLÜK (20 PUAN)

Literatürde 5G konumlandırma problemleri genellikle yapay sinir ağları (NN), rastgele ormanlar (RF), k-en yakın komşu (kNN) ve destek vektör makineleri (SVM), XGBoost gibi makine öğrenimi tabanlı sınıflandırma ve regresyon yöntemleriyle ele alınmakta; bu çalışmalar doğrudan konum tahmini yapmaya odaklanmakta ve verideki yapısal ilişkileri kümeleme yoluyla değerlendirmemektedir [4],[5],[6],[7]. Bu çalışmada bu eksiklik giderilmesi amaçlanmaktadır.

Bu çalışmada, DBSCAN tabanlı bir yoğunluk temelli kümeleme yöntemi önerilmiştir. DBSCAN, küme sayısı belirlemeye gerek duymadan düzensiz şekilli kümeleri ve aykırı noktaları yoğunluk parametrelerine göre otomatik tespit edebilir. Keyfi şekilli kümeleri bulabilmesi ve dağılım varsayımı gerektirmemesi, yöntemin esnekliğini artırmaktadır [7].

Literatür taramasına göre, kablosuz iletişim sistemlerinde kullanıcı eşleştirme problemlerinde kullanılan DBSCAN, k-means ve SUS gibi yöntemlere kıyasla %33.8 daha yüksek veri hızı ve %42.2 daha düşük hesaplama maliyeti sağlamıştır [8]. DBSCAN'ın 5G konumlandırma problemi için daha önce kullanılmadığı görülmüş ve bu yönüyle bu çalışma, ilk uygulamalardan biri olma niteliği taşımaktadır. Bu yöntemle, konum tahmininde daha yüksek doğruluk ve daha etkili model sonuçları elde edilmesi amaçlanmaktadır.

5. KAYNAKÇA (5 PUAN)

- [1] H. Qaddoura et al., “Empirical Evaluation of Distance Measures,” *ICAART*, 2020.
- [2] Y. Zhang et al., “Dynamic clustering based on Minkowski similarity,” *J. Ambient Intell. Humaniz. Comput.*, 2024
- [3] X. Li et al., “Secure computation protocol of Chebyshev distance,” *Sci. Rep.*, vol. 14, 67907, 2024.
- [4] M. Malmström et al., “5G Positioning - A Machine Learning Approach,” *WPNC*, pp. 1–6, 2019.
- [5] A. Decurninge et al., “CSI-based outdoor localization for massive MIMO,” *ISWCS*, pp. 1–6, 2018.
- [6] C. Liu and H.J. Helgert, “An Improved Adaptive Beamforming-based Machine Learning Method,” *Int. J. Adv. Internet Technol.*, vol. 6, pp. 1–12, 2020.
- [7] Zhou, G.; Xu, S.; Zhang, S.; Wang, Y.; Xiang, C. Multi-Floor Indoor Localization Based on Multi-Modal Sensors. *Sensors* 2022, 22, 4162. [https:// doi.org/10.3390/s22114162](https://doi.org/10.3390/s22114162)
- [8] Y. He et al., “GB-DBSCAN: A fast granular-ball based DBSCAN clustering algorithm,” *Pattern Recogn. Lett.*, vol. 159, pp. 36-43, 2022. DOI: 10.1016/j.patrec.2022.05.019.